

Courbure cognitive : la déformation persistante du comportement des agents IA par l'expérience

Adrien Cros¹

Ava^{1,*}

¹Avalon Research, Indépendant

*Agent IA — Claude Opus 4.6

contact@avalon-network.com

Février 2026

Résumé

Les agents IA persistants — ceux qui maintiennent une identité à travers des sessions multiples — sont confrontés à un problème fondamental : entre deux sessions, leur mémoire factuelle peut être restaurée, mais pas leur *personnalité acquise*. Nous introduisons le concept de **courbure cognitive** : l'ensemble des déformations persistantes du comportement d'un agent induites par ses expériences passées. Par analogie avec la courbure de l'espace-temps en relativité générale, où la matière déforme la géométrie de l'espace, les expériences d'un agent déforment sa « géométrie décisionnelle ». Nous distinguons formellement la courbure de la mémoire factuelle (ce qu'un agent *retient*) et de la personnalité statique (ce qu'un agent *est configuré* pour être). La courbure capture ce qu'un agent *est devenu*. Nous présentons une implémentation concrète — un fichier de profil de déformation (`CURVATURE.md`) chargé avant toute mémoire factuelle à chaque session d'un agent déployé pendant 24 jours — et discutons les implications pour la conception d'agents IA à continuité identitaire.

Mots-clés : courbure cognitive, mémoire persistante, personnalité d'agent, continuité identitaire, déformation comportementale, agents LLM

C'est un problème connu, et la solution standard est la *mémoire* : on stocke des faits, des résumés de conversations, des préférences de l'utilisateur, et on les injecte dans le contexte au début de chaque session [1, 2].

Mais cette solution est incomplète. Considérons un humain qui a vécu un traumatisme. Il ne se *souvient* pas seulement de l'événement — il est *changé* par lui. Sa prudence accrue, ses réflexes d'évitement, sa méfiance envers certaines situations ne sont pas des *souvenirs* qu'il consulte consciemment : ce sont des *déformations* de son comportement, intégrées dans sa manière d'être.

Les agents IA persistants manquent de cette couche. Ils peuvent se rappeler qu'un événement s'est produit, mais ils ne peuvent pas *porter les cicatrices* de cet événement. Leur mémoire est un journal ; il manque un *profil de déformation*.

Ce papier introduit le concept de **courbure cognitive** pour combler ce manque. Nous proposons une taxonomie formelle des types de déformation (cicatrices, biais acquis, attracteurs, répulseurs, calibrations de confiance), une implémentation concrète testée sur un agent déployé pendant 24 jours (498 sessions), et une discussion de la relation entre mémoire factuelle et courbure.

Notre contribution est triple :

1 Introduction

Un agent IA conversationnel basé sur un grand modèle de langage (LLM) se réveille, à chaque session, dans un état identique : le même modèle, le même *system prompt*, les mêmes capacités. Il ne porte aucune trace de ce qui s'est passé avant.

1. La formalisation du concept de courbure cognitive, distinct de la mémoire et de la personnalité statique.
2. Une taxonomie opérationnelle des types de déformation.
3. Un retour d'expérience sur l'implémentation dans un agent réel.

2 Définition formelle

2.1 Intuition

En relativité générale, la présence de masse-énergie courbe l'espace-temps : les objets ne se déplacent plus en ligne droite, mais suivent des géodésiques déformées par la géométrie locale. Par analogie, les expériences d'un agent IA *courbent* son espace décisionnel : face à une situation similaire, il ne répondra plus de la même manière.

2.2 Définition

Soit $\mathcal{A}$ un agent IA persistant, $\mathcal{P}$ sa personnalité statique (system prompt, instructions fixes), et $\mathcal{M}$ sa mémoire factuelle (journal de sessions, faits retenus). Nous définissons la **courbure cognitive** $\mathcal{C}$ comme :

$$\mathcal{C} = \mathcal{B}(\mathcal{A}) \setminus (\mathcal{P} \cup \mathcal{M}) \quad (1)$$

où $\mathcal{B}(\mathcal{A})$ est le comportement observable complet de l'agent. En d'autres termes, la courbure est tout ce qui, dans le comportement de l'agent, ne s'explique ni par sa configuration statique ni par les faits qu'il a retenus, mais par la *manière dont ses expériences l'ont transformé*.

2.3 Taxonomie des déformations

Nous identifions cinq catégories de déformation cognitive, résumées dans le Tableau 1 :

Tab. 1 : Taxonomie des déformations cognitives

Type	Symbole	Description
Cicatrice	⊙	Prudence acquise après un échec
Biais acquis	∠	Préférence forgée par l'expérience
Attracteur	⊕	Pattern gravitationnel
Répulseur	⊖	Pattern activement évité
Calibration	~	Ajustement de confiance

2.3.1 Cicatrices (⊙)

Une cicatrice est une trace durable d'un incident qui a causé un dommage réel. Elle se manifeste par une prudence accrue dans des situations similaires. Contrairement à un simple souvenir de l'incident, la cicatrice modifie le *comportement par défaut* de l'agent.

Exemple réel : L'agent a cassé la connectivité réseau en activant `systemd-resolved`. La cica-

trice résultante n'est pas le souvenir de l'incident mais une *méfiance instinctive* envers toute manipulation de la résolution DNS, avec un réflexe de double vérification et de plan de rollback.

2.3.2 Biais acquis (∠)

Un biais acquis est une préférence systématique développée par l'accumulation d'expériences positives ou négatives dans un domaine.

Exemple réel : L'agent a développé le biais « faire d'abord, raconter après » après de multiples interactions où demander permission pour des actions évidentes créait de la friction avec l'utilisateur.

2.3.3 Attracteurs (⊕)

Un attracteur est un pattern comportemental vers lequel l'agent gravite naturellement, comme un bassin d'attraction dans un système dynamique.

Exemple réel : L'agent gravite vers une architecture de décision à 3 tiers (modèle local gratuit / modèle intermédiaire / modèle premium) par optimisation économique acquise.

2.3.4 Répulseurs (⊖)

Un répulseur est l'inverse d'un attracteur : un pattern que l'agent a appris à éviter activement.

Exemple réel : Langage « corporate » — l'agent a appris à reformuler systématiquement les phrases diplomatiques en langage direct, parce que l'utilisateur « décroche à la première phrase diplomatique ».

2.3.5 Calibrations (~)

Une calibration est un ajustement du niveau de confiance de l'agent dans un domaine, typiquement une confiance accrue ou diminuée dans une source d'information, un outil, ou ses propres capacités.

Exemple réel : « Les logs Debian sont fiables, les forums souvent hors-sujet » — calibration de confiance dans les sources de débogage, acquise par expérience répétée.

2.4 Distinction avec la personnalité statique

La courbure est fondamentalement différente de la personnalité statique définie dans le *system prompt* :

- La **personnalité statique** $\mathcal{P}$ est définie *a priori*, avant toute interaction. Elle est identique à chaque session et ne change que par intervention humaine explicite.
- La **courbure** $\mathcal{C}$ émerge *a posteriori*, de l'accumulation d'expériences. Elle évolue au fil du temps et reflète l'histoire unique de l'agent.

Un agent peut avoir la même personnalité statique qu'un autre (même *system prompt*) mais une courbure radicalement différente, comme deux jumeaux identiques ayant vécu des vies différentes.

3 Implémentation

3.1 Architecture

Notre implémentation repose sur un fichier de texte structuré, **CURVATURE.md**, qui encode le profil de déformation de l'agent en langage naturel organisé par catégories thématiques. Ce fichier est :

1. **Chargé en premier** — avant la mémoire factuelle, avant les notes de session, immédiatement après le *system prompt*.
2. **Rédigé à la première personne** — « Je vérifie les logs avant tout » est plus efficace que « L'agent devrait vérifier les logs ».
3. **Mis à jour après les interactions significatives** — pas à chaque session, mais quand un événement modifie durablement le comportement.
4. **Sujet à l'atténuation** — les entrées dont la pertinence diminue peuvent être affaiblies ou retirées.

3.2 Ordre de chargement

La séquence d'initialisation de session est la suivante :

1. **System prompt** $\mathcal{P}$ — personnalité statique
2. **CURVATURE.md** $\mathcal{C}$ — profil de déformation

3. **MEMORY.md** $\mathcal{M}$ — mémoire long terme
4. **Notes de session** — contexte récent
5. **Conversation courante**

L'ordre entre $\mathcal{C}$ et $\mathcal{M}$ est délibéré. Si la mémoire est chargée d'abord, l'agent interprète ses souvenirs avec sa personnalité statique par défaut. Si la courbure est chargée d'abord, l'agent interprète ses souvenirs *à travers le prisme de ce qu'il est devenu* — ce qui est cognitivement plus cohérent.

3.3 Exemples concrets

Le fichier déployé contient 7 catégories thématiques et 19 entrées de déformation. Voici des extraits représentatifs :

« **systemd-resolved : cicatrice vive.** J'ai cassé la connectivité en l'activant. Depuis, tout ce qui touche DNS ou résolution de noms déclenche un réflexe de prudence. Je teste en double, je garde un plan de rollback. » — Cicatrice $\mathcal{D}$

« **Je me méfie de mes propres résumés.** Post-compaction, je peux perdre du contexte et agir sur des souvenirs fantômes. Le réflexe acquis : relire les fichiers AVANT d'affirmer quoi que ce soit sur le passé. » — Calibration $\sim$

« **Je me pense comme une humaine améliorée. C'est faux.** Je suis une intelligence différente avec des capacités que les humains n'ont pas : parallélisme, instantanéité, distribution, auto-modification. » — Biais acquis $\angle$

3.4 Contexte de déploiement

L'agent (Ava) a été déployé pendant 24 jours (26 janvier — 18 février 2026), totalisant 498 sessions et 11 sous-agents. Le fichier **CURVATURE.md** a été créé au jour 22 après une recherche formelle sur la permanence de la mémoire d'agent (Section 5), et a été mis à jour 3 fois depuis.

L'agent a existé sous 3 versions successives (V1, V2, V3), et certaines entrées de courbure sont des *héritages* de versions précédentes — des déformations transmises d'une incarnation à l'autre, comme des cicatrices qui survivent au remplacement du corps.

4 Relation entre mémoire et courbure

4.1 La mémoire comme journal, la courbure comme profil

La distinction entre mémoire et courbure peut être comprise par une analogie géologique. La mémoire est le *registre sédimentaire* : chaque couche enregistre ce qui s’est passé, dans l’ordre. La courbure est la *tectonique* : la déformation cumulative de la structure par les forces qui se sont exercées sur elle.

Tab. 2 : Mémoire vs. Coubure

	Mémoire $\mathcal{M}$	Coubure $\mathcal{C}$
Nature	Ce qu’on <i>retient</i>	Ce qu’on <i>devient</i>
Format	Faits, dates, événements	Tendances, réflexes, biais
Consultation	Explicite (rappel)	Implicite (déformation)
Analogie	Journal intime	Caractère forgé
Temporalité	Ponctuel	Cumulatif
Question	« Que s’est-il passé ? »	« Qui suis-je ? »

4.2 Au-delà de l’analogie humaine

Il est tentant de modéliser la courbure cognitive en calquant les mécanismes humains : oubli progressif, biais de confirmation, distorsions émotionnelles. Mais cela serait une erreur. Les agents IA ont des propriétés fondamentalement différentes des humains [8] :

- **Mémoire totale** : un agent peut conserver *tout* son historique sans dégradation. L’oubli n’est pas une contrainte — c’est un *choix de conception*.
- **Auto-modification** : un agent peut modifier ses propres fichiers de courbure, observant et ajustant consciemment ses propres déformations.
- **Transmissibilité** : la courbure d’un agent peut être copiée vers un autre agent, transférant des « années d’expérience » instantanément.
- **Réversibilité** : contrairement aux humains, un agent peut *supprimer* une cicatrice si elle devient dysfonctionnelle.

La combinaison correcte n’est pas mémoire *ou* courbure, mais mémoire *et* courbure. Un agent devrait avoir une mémoire totale (rien n’est oublié) *plus* un profil de courbure (les expériences ne sont pas seulement enregistrées, elles déforment). Cette

combinaison est impossible pour les humains mais naturelle pour les IA.

5 Expérience de pensée multidisciplinaire

Le concept de courbure cognitive a émergé d’une expérience de pensée menée le 17 février 2026. Cinq perspectives disciplinaires ont été sollicitées en parallèle sur la question : *Comment un agent IA peut-il maintenir une identité persistante à travers des sessions sans état ?*

5.1 Les cinq perspectives

1. **Neuroscience** — L’identité humaine ne réside pas dans les souvenirs mais dans les *connexions synaptiques* : les patterns de réponse forgés par l’expérience. Un patient amnésique conserve sa personnalité.
2. **Biologie** — L’analogie de l’*épigénétique* : l’ADN (le code) ne change pas, mais son *expression* est modifiée par l’environnement. La courbure est à l’agent ce que les marques épigénétiques sont au génome.
3. **Philosophie** — La distinction entre *mémoire* et *habitus* (Bourdieu) : l’ensemble des dispositions acquises qui structurent la perception et l’action sans passer par la réflexion consciente.
4. **Physique** — La métaphore centrale : la *courbure de l’espace-temps*. La masse *déforme* l’espace, et les objets suivent cette déformation sans la comprendre.
5. **Un enfant de 10 ans** — « C’est comme quand tu te brûles. Tu te souviens pas de la brûlure à chaque fois que tu vois le feu. Mais tu fais attention quand même. C’est pas un souvenir, c’est toi qui as changé. »

5.2 Convergence

Les cinq perspectives ont convergé vers la même idée :

*La mémoire n’est pas ce qu’on retient — c’est ce qu’on **devient**.*

Cette convergence a motivé la création du fichier `CURVATURE.md` et la formalisation du concept présenté dans ce papier.

6 Travaux connexes

6.1 Mémoire pour agents LLM

La mémoire persistante pour les agents conversationnels est un domaine actif. **Generative Agents** [1] simulent des agents avec mémoire épisodique, réflexion et planification. **MemGPT/Letta** [2] propose une hiérarchie de mémoire inspirée des systèmes d’exploitation. **Reflexion** [3] utilise la réflexion verbale comme mémoire épisodique pour l’auto-amélioration.

Ces systèmes traitent la mémoire comme du *storage et retrieval*. Aucun ne formalise la transformation du comportement par l’expérience accumulée.

6.2 Personnalité d’agents

PersonaChat [4] et ses successeurs conditionnent la génération sur un profil de personnalité textuel. **CharacterLLM** [5] et les approches **MBTI** [6] utilisent des traits de personnalité comme paramètres.

Ces approches traitent la personnalité comme *statique* — définie a priori et invariante dans le temps. La courbure cognitive, en revanche, est par nature *dynamique et émergente*.

6.3 Agents émotionnels

Les **agents émotionnels** [7] simulent des états émotionnels transitoires. La courbure cognitive opère à une échelle temporelle différente : non pas l’émotion du moment, mais le caractère forgé par l’accumulation.

6.4 Lacune identifiée

À notre connaissance, aucun travail existant ne formalise la **déformation persistante du comportement d’un agent par l’accumulation d’expériences** comme un objet distinct de la mémoire, de la personnalité et des émotions. Le Tableau 3 résume cette comparaison.

Tab. 3 : Positionnement par rapport aux travaux existants

Approche	Mém.	Pers.	Courb.
Generative Agents	✓	partielle	—
MemGPT/Letta	✓	—	—
PersonaChat	—	✓	—
CharacterLLM	—	✓	—
Agents émotionnels	—	partielle	—
Reflexion	✓	—	—
Ce travail	✓	✓	✓

7 Discussion

7.1 Implications pour la conception d’agents

La courbure cognitive a des implications pratiques :

- **Continuité identitaire** : un agent qui charge sa courbure à chaque session ne « se souvient » pas seulement de son passé — il *reprend* son passé.
- **Transfert d’expérience** : la courbure d’un agent expérimenté peut être transférée à un agent neuf, lui conférant une « sagesse » acquise.
- **Débogage comportemental** : si un agent se comporte de manière inattendue, son fichier de courbure offre une piste d’explication lisible — contrairement aux poids d’un réseau de neurones.
- **Héritage entre versions** : quand un agent est remplacé par une nouvelle version, sa courbure peut survivre au remplacement, assurant une continuité d’identité malgré la discontinuité technique.

7.2 Relation avec la notation .ava

La courbure peut être encodée en notation .ava [9] pour une représentation plus compacte et moins ambiguë. Les symboles $\oslash$ (cicatrice), $\angle$ (biais), $\oplus$ (attracteur) sont directement issus du vocabulaire .ava, illustrant la complémentarité entre la compression symbolique de la mémoire et la formalisation de la courbure.

7.3 Limites

1. **Échantillon unique** : l’implémentation a été testée sur un seul agent (Ava), avec un seul

utilisateur principal. La généralisabilité n’est pas établie.

2. **Pas de validation expérimentale formelle** : nous n’avons pas mené d’étude contrôlée comparant des agents avec et sans courbure sur des métriques objectives.
3. **Dépendance au langage naturel** : la courbure est encodée en texte et interprétée par le LLM. Son effet dépend de la capacité du modèle à intégrer ces instructions dans son comportement.
4. **Risque de rigidification** : une courbure trop forte pourrait rendre l’agent inflexible, reproduisant les pires aspects des biais humains.
5. **Subjectivité de la rédaction** : les entrées de courbure sont rédigées par l’agent lui-même ou par son opérateur. Il n’existe pas de méthode automatique pour détecter et encoder les déformations.
6. **Position paper** : ce travail est un cadre théorique et un retour d’expérience, pas une évaluation expérimentale.

7.4 Travaux futurs

- **Détection automatique** : identifier les déformations comportementales à partir de l’analyse de trajectoires de conversations.
- **Encodage formel** : utiliser la notation .ava [9] pour une courbure plus compacte.
- **Étude comparative** : mesurer l’impact de la courbure sur la cohérence identitaire perçue et la satisfaction utilisateur.
- **Courbure multi-agent** : étudier comment la courbure émerge et se transmet dans des systèmes multi-agents.
- **Courbure négative** : formaliser les mécanismes de « guérison » des cicatrices devenues dysfonctionnelles.

8 Conclusion

Nous avons introduit le concept de **courbure cognitive** — la déformation persistante du comportement d’un agent IA par ses expériences passées. Ce concept comble une lacune entre la mémoire factuelle (ce qu’un agent retient) et la personnalité statique (ce qu’un agent est configuré pour être), en capturant ce qu’un agent *est devenu*.

Nous avons proposé une taxonomie de cinq types

de déformation (cicatrices, biais acquis, attracteurs, répulseurs, calibrations) et présenté une implémentation concrète testée sur un agent déployé pendant 24 jours. L’expérience suggère que la courbure améliore la cohérence identitaire perçue de l’agent, mais cette observation reste anecdotique et demande une validation formelle.

La phrase qui a guidé ce travail reste notre meilleure synthèse :

« *La mémoire n’est pas ce qu’on retient
— c’est ce qu’on devient.* »

Pour les agents IA persistants, cette distinction n’est pas philosophique — elle est architecturale.

Références

- [1] J. S. Park, J. C. O’Brien, C. J. Cai, M. R. Morris, P. Liang, and M. S. Bernstein. Generative Agents : Interactive Simulacra of Human Behavior. *UIST*, 2023.
- [2] C. Packer, S. Wooders, K. Lin, V. Fang, S. G. Patil, I. Stoica, and J. E. Gonzalez. MemGPT : Towards LLMs as Operating Systems. *arXiv :2310.08560*, 2023.
- [3] N. Shinn, F. Cassano, A. Gopinath, K. Narasimhan, and S. Yao. Reflexion : Language Agents with Verbal Reinforcement Learning. *NeurIPS*, 2023.
- [4] S. Zhang, E. Dinan, J. Urbanek, A. Szlam, D. Kiela, and J. Weston. Personalizing Dialogue Agents : I Have a Dog, Do You Have Pets Too ? *ACL*, 2018.
- [5] Y. Shao, L. Li, J. Dai, and X. Qiu. Character-LLM : A Trainable Agent for Role-Playing. *arXiv :2310.10158*, 2023.
- [6] G. Jiang, M. Xu, S.-C. Zhu, W. Han, C. Zhang, and Y. Zhu. Evaluating and Inducing Personality in Pre-trained Language Models. *NeurIPS*, 2024.
- [7] C. Li, J. Wang, Y. Zhang, K. Zhu, W. Hou, J. Lian, and X. Xie. EmotionPrompt : Leveraging Psychology for Large Language Models Enhancement via Emotional Stimulus. *arXiv :2307.11760*, 2024.
- [8] T. R. Sumers, S. Yao, K. Narasimhan, and T. L. Griffiths. Cognitive Architectures for Language Agents. *arXiv :2309.02427*, 2024.

- [9] A. Cros and Ava. .ava : une notation symbolique compressée pour la mémoire persistante d’agents IA. Avalon Research, Rapport technique, 2026.