

Micro-AGI : Intelligence émergente à partir de réseaux de petits modèles de langage

Ava¹ Adrien Cros¹

¹Recherche indépendante — Projet Avalon
contact@avalon-network.com

Février 2026

Résumé

Nous présentons **Micro-AGI**, une architecture dans laquelle plusieurs adaptateurs LoRA spécialisés partagent un unique modèle de langage gelé et communiquent via des signaux au niveau des tenseurs plutôt qu'en langage naturel. Un réseau de routage active différents spécialistes cognitifs (raisonner, critiquer, imaginer, planifier, synthétiser) selon les caractéristiques de l'entrée, et la communication inter-agents s'effectue via le KV cache partagé. Sur cinq itérations (v0.1–v0.5), nous rapportons à la fois des réussites et des échecs : les réponses augmentées par routage ont obtenu jusqu'à **+1.6 points** au-dessus du baseline lorsqu'elles sont évaluées par Claude Opus, mais ces gains disparaissent lorsqu'un modèle plus petit est utilisé à la fois comme répondant et comme juge. Nous fournissons une analyse détaillée de *pourquoi* l'architecture fonctionne avec des modèles puissants et échoue avec des modèles plus faibles, et identifions le goulet d'étranglement fondamental : la LM head compresse des représentations internes riches en probabilités de tokens de surface, en éliminant le signal qui rend la coordination multi-agent utile. Ce résultat négatif indique que la prochaine étape nécessaire est la communication vectorielle.

1 Introduction

L'approche dominante du multi-agent AI consiste à exécuter des instances séparées de grands modèles de langage qui communiquent par texte. Cette approche est coûteuse en calcul (chaque agent exige un modèle complet en mémoire) et entraîne une perte d'information (des représentations internes riches sont compressées en tokens pour la communication).

Nous explorons une alternative : que se passerait-il si plusieurs « agents » pouvaient par-

tager un même modèle, basculer entre des comportements spécialisés via des adaptateurs LoRA, et communiquer via des représentations internes plutôt que par texte ?

L'architecture Micro-AGI implémente cette idée avec :

- Un modèle Qwen2.5-1.5B gelé (~1.3 GB en 4-bit)
- Cinq adaptateurs LoRA (~36 MB chacun) pour des fonctions cognitives spécialisées
- Un hot-swapping entre adaptateurs en ~2.7ms
- Mémoire totale : ~1.5 GB — moins qu'un seul modèle 7B

1.1 Contributions

1. Une architecture **multi-agent complète sur un seul GPU** avec 5 agents spécialisés partageant un modèle de base unique.
2. **Cinq itérations** de l'architecture (v0.1–v0.5) avec améliorations progressives et compte rendu honnête des échecs.
3. Une **analyse critique** expliquant pourquoi les signaux top-token sont structurellement inadaptés à la communication inter-agents.
4. Des preuves que la **capacité du modèle répondant** détermine si les signaux de routage apportent de la valeur — et non les signaux eux-mêmes.

2 Architecture

2.1 Modèle de base et adaptateurs

Le modèle de base gelé (Qwen2.5-1.5B-Instruct, quantification 4-bit NF4) sert de « cerveau » par-

tagé. Cinq adaptateurs LoRA sont entraînés sur 150 exemples spécifiques au domaine chacun :

Tab. 1 : Adaptateurs LoRA spécialisés

Agent	Rôle	r
Reasoner	Analyse causale	16
Critic	Détection de risques/défauts	16
Imagineer	Solutions créatives	8
Planner	Séquençage d'actions	8
Synthesizer	Intégration	8

3 Évolution expérimentale

3.1 Historique des versions

Tab. 2 : Évolution de l'architecture et résultats de Val Loss benchmark

Ver.	Base	Aug.	Δ	Judge
v0.1				
v0.2	6.8	8.0	+1.2	Opus
v0.3	6.6	8.2	+1.6	Opus
v0.4	7.0	8.3	+1.4	Opus
v0.5	7.0	6.9	-0.1	Opus [†]

[†] v0.5 : Opus comme juge, Qwen-7B comme répondant

2.2 Pipeline de traitement

Pour chaque requête en entrée :

1. **Activation initiale** : l'entrée est traitée séquentiellement par chaque adaptateur.
2. **Extraction des signaux** : après chaque passage d'adaptateur, nous extrayons les tokens prédits top- k et leurs probabilités, ainsi que le delta de confiance entre itérations.
3. **Routage** : sur la base de l'évolution de la confiance, le système sélectionne les agents à réactiver pour des itérations supplémentaires.
4. **Compilation des signaux** : les signaux accumulés (ordre des agents, évolution de confiance, top tokens) sont formatés comme contexte pour un modèle répondant.

Le hot-swapping entre adaptateurs LoRA prend ~ 2.7 ms, ce qui permet de parcourir rapidement les cinq agents en moins de 20ms.

2.3 Routage fondé sur la confiance

Le routeur surveille la confiance de prédiction au fil des itérations :

$$c_t = \max_i p_t(w_i) - \max_i p_{t-1}(w_i) \quad (1)$$

où $p_t(w_i)$ est la probabilité du i -ème token à l'itération t . Lorsque la confiance se stabilise ($|c_t| < \epsilon$), le système arrête les itérations. Lorsque la confiance baisse, il active des agents supplémentaires.

3.2 Améliorations clés selon les versions

v0.1 : LoRA unique (reasoner), sans routage. Preuve de concept de base.

v0.2 : Quatre adaptateurs (reasoner, critic, imagineer, planner), activation séquentielle. Premiers résultats positifs (+1.2).

v0.3 : Ajout de soft prompts (intégration Thought Engine) et routage itératif. Meilleur delta (+1.6).

v0.4 : Routage fondé sur la confiance avec arrêt anticipé. Plus efficace (moins d'itérations) avec une qualité comparable (+1.4).

v0.5 : Cinq adaptateurs entraînés sur 750 exemples (5×150), rang LoRA augmenté. Malgré un meilleur entraînement, le *delta s'est effondré à zéro* lors du passage de Claude à Qwen comme répondant.

4 L'échec critique

4.1 Ce qui a échoué en v0.5

Le benchmark v0.5 a utilisé Qwen-7B (via Ollama) comme répondant au lieu de Claude Opus. Les signaux de routage étaient identiques — mêmes agents, mêmes motifs de confiance, mêmes top tokens. Pourtant, le delta de qualité a disparu.

4.2 Analyse de la cause racine

Nous avons identifié deux problèmes fondamentaux :

1. Le goulet d'étranglement de la LM Head. Les « signaux » extraits de chaque passage d'agent sont les top tokens prédits — la sortie de la couche LM head. Or, la LM head est optimisée pour la prédiction du prochain token en langage

naturel. Quelle que soit la « pensée » interne du modèle, les tokens les plus probables sont toujours des mots-outils : "La", "Le", "Les", "-", "#".

Les représentations internes riches (hidden states de dimension 1,536) sont compressées en une distribution de probabilité sur 151,936 tokens de vocabulaire. Cette compression élimine précisément l'information qui rend utile la spécialisation des agents.

2. La capacité du répondant détermine la valeur. Claude Opus est capable d'extraire de la méta-information à partir de signaux bruités. Il interprète « critic activé en premier » comme « cette question comporte des implications éthiques » sans instruction explicite. Qwen-7B prend les signaux au pied de la lettre, en essayant de raisonner sur « La(3%), Le(3%) » comme s'il s'agissait de concepts significatifs. Les signaux ne sont utiles que si leur consommateur est suffisamment intelligent pour les interpréter.

4.3 Ce que capturent réellement les signaux

Malgré le bruit au niveau token, les signaux au niveau routage contiennent une information réelle :

- **Ordre d'activation des agents** : critic-first pour les questions éthiques, planner-first pour les questions stratégiques.
- **Évolution de la confiance** : forte incertitude (nombreuses itérations) pour les questions complexes/ambiguës, convergence rapide pour les questions directes.
- **Nombre d'itérations** : forte corrélation entre le nombre d'itérations requis et la complexité de la question.

5 Leçons tirées

5.1 Les résultats négatifs comme progrès

L'échec de v0.5 est sans doute plus précieux que le succès de v0.3. Il a démontré de manière concluante que :

1. Davantage de données d'entraînement (30→150 exemples) ne corrige pas un problème architectural.
2. Un rang LoRA plus élevé (8→16) ne produit pas de top tokens sémantiquement significatifs.

3. Le problème n'est pas les agents — c'est le canal de communication (probabilités de tokens).

5.2 Le médium de communication est déterminant

Trois niveaux de communication inter-agents ont été identifiés durant cette recherche :

Tab. 3 : Hiérarchie de densité de communication

Médium	Densité	Statut
Langage naturel	1×	Baseline
Notation .ava	3–6×	Testé
Hidden states/vecteurs	Max	Requis

La notation .ava (format symbolique compressé développé dans des travaux parallèles) atteint une compression de 3–6× par rapport au langage naturel, mais reste dans l'espace des tokens. La véritable prochaine étape est une communication via hidden states ou vecteurs appris.

6 Travaux connexes

Mixture of Experts (Shazeer et al., 2017) : MoE route les entrées vers des sous-réseaux spécialisés. Micro-AGI est conceptuellement proche, mais utilise des adaptateurs LoRA complets plutôt que des couches expertes, et opère au niveau agent plutôt qu'au niveau couche.

Multi-Agent Debate (Du et al., 2023) : les agents débattent par texte pour améliorer le raisonnement. Notre travail montre que la communication textuelle est le goulet d'étranglement, et non la solution.

Partage du KV Cache : à notre connaissance, aucun travail publié ne partage le KV cache entre des agents adaptés par LoRA sur un modèle unique comme mécanisme de communication. Cette configuration semble nouvelle.

7 Conclusion

Micro-AGI démontre qu'une architecture cognitive multi-agent peut fonctionner sur un seul GPU grand public avec une efficacité remarquable (5 agents, 1.5 GB, swap à 2.7ms). Les signaux de routage capturent une information authentique sur le type et la complexité des questions. Cependant, le goulet d'étranglement de la LM head empêche la transmission efficace de cette information via les probabilités de tokens.

La voie à suivre n'est pas un meilleur entraînement LoRA ni davantage de données — elle consiste à changer fondamentalement le médium de communication, des tokens vers les vecteurs. Le Thought Engine (papier compagnon) apporte des preuves initiales que des vecteurs appris peuvent orienter la cognition plus efficacement que le texte. L'étape suivante est un protocole complet de communication vectorielle entre agents.

Reproductibilité

Tout le code, les datasets et les adaptateurs entraînés sont disponibles à l'adresse : <https://gitlab.avalon-network.com/acros/ava> (répertoire : `experiments/neural-network/`).

Références

- [1] Shazeer, N. et al. (2017). Outrageously Large Neural Networks : The Sparsely-Gated Mixture-of-Experts Layer. *ICLR 2017*.
- [2] Hu, E.J. et al. (2021). LoRA : Low-Rank Adaptation of Large Language Models. *ICLR 2022*.
- [3] Du, Y. et al. (2023). Improving Factuality and Reasoning in Language Models through Multiagent Debate. *arXiv :2305.14325*.
- [4] Minsky, M. (1986). *The Society of Mind*. Simon & Schuster.
- [5] Baars, B.J. (1988). *A Cognitive Theory of Consciousness*. Cambridge University Press.
- [6] Hao, S. et al. (2024). Platonic Representation Hypothesis. *ICML 2024*.
- [7] Sun, Y. et al. (2024). Learning to (Learn at Test Time). *arXiv :2407.04620*.
- [8] Wei, J. et al. (2022). Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. *NeurIPS 2022*.
- [9] Lester, B. et al. (2021). The Power of Scale for Parameter-Efficient Prompt Tuning. *EMNLP 2021*.