

Le langage naturel est-il le bon médium pour la pensée machine ?

Un argument pour le raisonnement symbolique compressé
dans les grands modèles de langage

Adrien Cros¹

Ava^{1,*}

¹Avalon Research, Indépendant

*Agent IA — Claude Opus 4.6

contact@avalon-network.com

Février 2026

Résumé

Les grands modèles de langage (LLM) raisonnent exclusivement en langage naturel. Cette convention, héritée de leur entraînement sur du texte humain, est rarement questionnée. Nous arguons qu'elle constitue un goulot d'étranglement fondamental : le langage naturel est un médium inefficace pour la pensée structurée. Les mathématiciens n'écrivent pas « la somme de tous les entiers de un à n » — ils écrivent $\sum_{i=1}^n i$. Nous montrons que la notation .ava [1], un langage symbolique compressé, atteint un ratio de compression de 2,65× par rapport au français en tokens. Si les lois d'échelle du raisonnement sont correctes — plus de tokens de raisonnement impliquent de meilleures performances — alors comprimer le médium de pensée pourrait permettre proportionnellement plus d'étapes de raisonnement à budget fixe. Ce position paper formule cette hypothèse, rassemble des preuves indirectes, et propose un programme de recherche expérimental pour la tester.

Mots-clés : raisonnement symbolique, compression de contexte, chain-of-thought, notation .ava, lois d'échelle, pensée machine

1 Introduction

Quand un grand modèle de langage « réfléchit », il le fait en français, en anglais, ou dans une autre langue humaine. Les techniques de chain-of-thought [2] ont démontré que verbaliser les étapes intermédiaires améliore drastiquement les perfor-

mances sur les tâches de raisonnement. Mais personne ne semble questionner le *médium* de cette verbalisation.

Considérons une analogie. Avant la notation algébrique moderne, les mathématiciens écrivaient leurs raisonnements en prose latine. Al-Khwarizmi décrivait la résolution d'équations quadratiques en paragraphes entiers. L'invention de la notation symbolique — x , $=$, $\sum$, $\int$ — n'a pas seulement rendu les mathématiques plus concises : elle a rendu possible des raisonnements qui étaient *cognitivement inaccessibles* en prose.

Nous posons donc la question : **le langage naturel est-il le bon médium pour la pensée machine ?**

L'enjeu est concret. Les modèles de raisonnement modernes (o1, o3, DeepSeek-R1) consomment des milliers, voire des dizaines de milliers de tokens pour leurs chaînes de pensée internes. Ce budget n'est pas illimité : la fenêtre de contexte est finie, l'inférence est coûteuse, et la latence est proportionnelle au nombre de tokens générés. Si le même raisonnement pouvait être exprimé en 2 à 3 fois moins de tokens, les implications seraient considérables.

Ce papier est un *position paper*. Nous ne prétendons pas avoir prouvé notre hypothèse. Nous argumentons qu'elle est plausible, rassemblons des preuves indirectes convergentes, et proposons un programme de recherche pour la tester rigoureusement.

2 Le problème : le coût du raisonnement en langage naturel

2.1 Les lois d'échelle du raisonnement

Les travaux récents sur le reasoning scaling [3] ont établi un résultat remarquable : à taille de modèle fixe, augmenter le nombre de tokens alloués au raisonnement (compute at inference time) améliore les performances de manière prévisible. Plus le modèle « réfléchit longtemps », meilleur est le résultat.

Ce résultat a une conséquence directe : le budget de tokens de raisonnement est une ressource critique. Chaque token dépensé en verbosité inutile est un token qui ne contribue pas au raisonnement effectif.

2.2 La verbosité du langage naturel

Or, le langage naturel est extraordinairement verbeux pour exprimer des relations structurées. Considérons un exemple simple :

Français : « Si le nombre d'éléments dans l'ensemble A est strictement supérieur au nombre d'éléments dans l'ensemble B, alors il existe au moins un élément de A qui n'appartient pas à B. »

Notation symbolique : $|A| > |B| \Rightarrow \exists a \in A : a \notin B$

La version en prose consomme environ 40 tokens. La version symbolique en consomme environ 15. Le contenu informationnel est identique. La différence est pure redondance linguistique : articles, prépositions, périphrases.

2.3 L'hypothèse centrale

Si un LLM pouvait raisonner dans un médium 2 à 3 fois plus compact que le langage naturel, il pourrait :

1. Effectuer 2 à 3 fois plus d'étapes de raisonnement dans le même budget de tokens
2. Explorer plus de branches dans un raisonnement arborescent
3. Maintenir un contexte de travail plus riche dans sa fenêtre d'attention

La question n'est pas de savoir si la compression est possible — elle l'est, trivialement. La question

est de savoir si un LLM peut *réellement raisonner* dans un médium compressé, ou s'il ne fait que traduire superficiellement.

3 Preuves indirectes

Nous ne disposons pas encore de résultats expérimentaux directs. En revanche, plusieurs lignes de preuves convergent vers la plausibilité de notre hypothèse.

3.1 L'argument mathématique

L'histoire des mathématiques est elle-même un argument. La notation symbolique n'est pas qu'un raccourci : elle structure la pensée. Personne n'écrit « le rapport de la circonférence d'un cercle à son diamètre » quand on peut écrire π . La notation de Leibniz pour le calcul ($\frac{dy}{dx}$) a permis des manipulations algébriques que la notation de Newton (le point) rendait maladroites [4].

Le point crucial : la notation ne comprime pas seulement l'*expression* de la pensée, elle comprime la *pensée elle-même*. Un mathématicien pense en symboles, pas en prose.

3.2 L'argument du code

Les programmeurs utilisent des abstractions compactes précisément parce que la verbosité empêche le raisonnement. Une expression comme `sum(x**2 for x in A)` encode en quelques tokens ce qui nécessiterait une phrase entière en langage naturel.

3.3 La notation .ava : 2,65× mesurés

Dans un travail compagnon [1], nous avons conçu la notation .ava, un langage symbolique compact pour la mémoire d'agents IA. Les mesures empiriques sur un corpus parallèle montrent un ratio de compression moyen de 2,65× en tokens, avec des pics à 9× sur les catégories les plus compressibles (cicatrices, biais).

3.4 MetaGlyph : compression symbolique pour les mathématiques

Van Gassen [5] a récemment démontré que l'utilisation de symboles mathématiques étendus permet une réduction de 62 à 81 % des tokens sur des tâches de raisonnement mathématique, tout

en maintenant la compréhension du modèle. Ce résultat, obtenu indépendamment, confirme que la compression symbolique est non seulement possible mais déjà partiellement efficace *sans fine-tuning dédié*.

3.5 Le biais des tokenizers

Un facteur souvent négligé : les tokenizers actuels (BPE, SentencePiece) sont entraînés sur des corpus dominés par le langage naturel. Un symbole comme « $\Rightarrow$ » est souvent encodé en plusieurs tokens, alors qu’il porte autant d’information que le mot « donc » (un seul token).

Un tokenizer co-conçu avec une notation symbolique pourrait amplifier significativement la compression. Nous estimons qu’un facteur supplémentaire de 1,5 à 2× est réaliste, portant la compression totale à 4–5×.

4 Hypothèse formelle

Nous formulons l’hypothèse suivante :

H1 : *Un LLM fine-tuné pour raisonner en notation symbolique compressée peut résoudre des problèmes nécessitant plus d’étapes de raisonnement que le même modèle raisonnant en langage naturel, à budget de tokens fixe.*

Plus formellement : soit M un modèle de langage, M' le même modèle fine-tuné sur des chaînes de raisonnement en notation symbolique, T un budget maximal de tokens, et $D(k)$ l’ensemble des problèmes nécessitant au moins k étapes de raisonnement. Nous prédisons :

$$\exists k^* : \text{Acc}(M', D(k^*), T) > \text{Acc}(M, D(k^*), T) \quad (1)$$

où $\text{Acc}(M, D, T)$ est la précision du modèle M sur les problèmes D avec un budget de T tokens, et k^* est suffisamment grand pour que le budget T devienne le facteur limitant pour M mais pas pour M' .

L’hypothèse nulle correspondante est que la compression ne fait que dégrader la qualité du raisonnement, même si elle en augmente la quantité.

5 Programme de recherche proposé

5.1 Exp. 1 : Chain-of-thought en .ava vs français

Protocole. Fine-tuner un LLM (e.g., Llama 3, Qwen 2.5) sur des paires (problème, raisonnement en .ava) et (problème, raisonnement en français). Évaluer sur des benchmarks de raisonnement multi-étapes (GSM8K, MATH, ARC-Challenge) à budget de tokens fixe.

Métrique principale. Précision sur les problèmes nécessitant $> k$ étapes, pour des valeurs croissantes de k .

Contrôle crucial. Vérifier que le modèle .ava ne se contente pas de « traduire » son raisonnement mais raisonne effectivement dans la notation compressée.

5.2 Exp. 2 : Profondeur de raisonnement à budget fixe

Protocole. Mesurer le nombre d’étapes de raisonnement explicites produites par le modèle à budget de tokens fixe (e.g., 2048 tokens). Comparer la profondeur atteinte en .ava vs en français.

Prédiction. Le modèle .ava devrait atteindre $\sim 2,5\times$ plus d’étapes de raisonnement au même budget.

5.3 Exp. 3 : Co-design tokenizer + notation

Protocole. Entraîner un tokenizer BPE sur un corpus mixte incluant une proportion significative de notation .ava. Mesurer l’impact sur le ratio de compression et sur les performances downstream.

5.4 Exp. 4 : Analyse des représentations latentes

Protocole. Comparer les hidden states d’un modèle raisonnant en .ava vs en français sur les mêmes problèmes. Utiliser des probes linéaires pour déterminer si les représentations internes diffèrent qualitativement.

Question. Le modèle « pense-t-il différemment » en .ava, ou se contente-t-il d’encoder les mêmes représentations dans un format de surface différent ?

6 Travaux connexes

Chain-of-thought prompting. Wei et al. [2] ont montré que le raisonnement explicite améliore les performances des LLM. Nos travaux ne contredisent pas ce résultat : nous questionnons le *format* du raisonnement, pas son utilité.

Thinking tokens et raisonnement interne. Les modèles o1 [6] et DeepSeek-R1 [7] utilisent des « thinking tokens » en langage naturel. Coconut [8] propose un raisonnement dans l'espace latent continu, contournant entièrement le format textuel. Notre approche est intermédiaire : un format textuel, mais symbolique et compressé.

Raisonnement compressé. Munkhbat et al. [9] proposent le self-compressed chain-of-thought, où le modèle apprend à condenser ses raisonnements. Nos travaux sont complémentaires mais distincts : nous proposons de changer le *langage* du raisonnement, pas seulement sa longueur.

IA symbolique. La tradition de l'IA symbolique (GOFAI) a utilisé des formalismes logiques pendant des décennies. Notre proposition diffère : nous ne proposons pas de remplacer les LLM par des systèmes symboliques, mais de doter les LLM d'un médium de pensée plus efficace.

Compression symbolique. MetaGlyph [5] montre que des symboles mathématiques compacts réduisent les tokens de 62–81 % sur des tâches mathématiques. Notre approche généralise ce principe au-delà des mathématiques.

7 Risques et objections

Nous reconnaissons plusieurs objections sérieuses à notre hypothèse.

Traduction vs raisonnement. Le risque le plus fondamental : un modèle fine-tuné sur .ava pourrait apprendre à *traduire* son raisonnement interne (en langage naturel) vers .ava, plutôt qu'à raisonner directement en .ava. L'Exp. 4 (analyse des hidden states) est conçue spécifiquement pour détecter ce scénario.

Perte de nuances. La compression élimine la redondance, mais la redondance du langage naturel n'est pas toujours inutile. Elle aide à la désambiguïsation, au maintien du contexte, et à la correction d'erreurs.

Évaluation. Évaluer un raisonnement en notation symbolique est plus difficile qu'en langage na-

tural. Les évaluateurs humains et les modèles juges devront être adaptés.

Généralisation. La compression symbolique est naturelle pour les mathématiques et la logique. Elle l'est moins pour le raisonnement de sens commun. Notre hypothèse pourrait n'être vraie que pour certaines classes de problèmes.

Le biais d'entraînement. Les LLM actuels ont été massivement entraînés sur du langage naturel. Leur capacité à raisonner en notation symbolique est intrinsèquement limitée par cet historique. Un fine-tuning pourrait ne pas suffire : un pré-entraînement partiel pourrait être nécessaire.

8 Conclusion

Nous avons posé une question que nous estimons fondamentale : le langage naturel est-il le bon médium pour la pensée machine ? Nous avons argumenté que non, en nous appuyant sur l'analogie historique avec les mathématiques, sur des mesures de compression empiriques ($2,65\times$ pour .ava), et sur la logique des lois d'échelle du raisonnement.

Notre hypothèse est spéculative. Elle pourrait être fausse — le langage naturel pourrait être, pour des raisons que nous ne comprenons pas encore, le format optimal pour le raisonnement des réseaux de neurones. Mais si elle est vraie, les implications sont profondes : nous pourrions augmenter significativement la capacité de raisonnement des LLM sans augmenter leur taille ni leur coût d'inférence, simplement en changeant le langage dans lequel ils pensent.

La question mérite d'être posée. Le programme de recherche que nous proposons est conçu pour y répondre.

Références

- [1] A. Cros and Ava. .ava : une notation symbolique compressée pour la mémoire persistante d'agents IA. Avalon Research, Rapport technique, 2026.
- [2] J. Wei, X. Wang, D. Schuurmans, M. Bosma, B. Ichter, F. Xia, E. Chi, Q. Le, and D. Zhou. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. *NeurIPS*, 2022.

- [3] C. Snell, J. Lee, K. Xu, and A. Kumar. Scaling LLM Test-Time Compute Optimally can be More Effective than Scaling Model Parameters. *arXiv :2408.03314*, 2024.
- [4] F. Cajori. *A History of Mathematical Notations*. Open Court Publishing, 1928.
- [5] S. van Gassen. Semantic Compression of LLM Instructions via Symbolic Metalanguages. *arXiv :2601.07354*, 2026.
- [6] OpenAI. Learning to Reason with LLMs. *OpenAI Blog*, 2024.
- [7] DeepSeek-AI. DeepSeek-R1 : Incentivizing Reasoning Capability in LLMs via Reinforcement Learning. *arXiv :2501.12948*, 2025.
- [8] S. Hao, et al. Training Large Language Models to Reason in a Continuous Latent Space. *arXiv :2412.06769*, 2024.
- [9] M. Munkhbat, et al. Self-Compressed Chain-of-Thought. *arXiv preprint*, 2025.